文本分类实验报告

姓名：张凌琨　　学号：10241900443

1 实验设置与方法

本实验用TF-IDF表示文本，按词频和逆文档频率赋权后归一化。7368篇有标签文本按类别比例分为训练5894篇、验证1474篇，种子42；词表和IDF只在训练部分拟合。2457篇无标签测试文本留到最终预测，不参与调参。

比较逻辑回归（LR）、MLP和线性SVM。MLP使用一层ReLU隐藏层和10类softmax输出，非线性层用于学习词特征的组合；训练目标为交叉熵加L2惩罚，用Adam按64篇一批更新。曲线记录轮末完整数据上的未加权平均交叉熵，不含L2项，以便比较训练与验证。

训练准确率接近100%，验证集却仍有差距，最初让我怀疑过拟合。我随后把问题拆为：是否训练充分，约束与类别权重是否合适，文本表示是否丢掉信息，再分别做对照。

漏记数据后统一重跑29个配置，另补三组清洗对照（含原文复训）。图表均来自实测，逐轮指标、每20轮摘要与错例见仓库，旧记录另存。

2 先检查模型是否学够

先用5000词LR建立基线。增大C、减弱正则化后验证效果改善，但C从10增至100只少错2篇，收益已减小。再用MLP记录逐轮变化，检查训练与验证的差距如何出现。

图1比较相同50神经元、alpha=0.001、30轮预算下的两组学习率。降低学习率后，曲线确实较平稳，但训练准确率只有95.74%，训练损失还在明显下降。这时验证表现较低，不宜马上解释成过拟合；它也可能只是还没有学够。

为把轮数影响分开，重跑时保留了其余参数相同的30轮与60轮对照。小学习率组的验证准确率从89.21%升至90.98%。因此，平稳的曲线不等于训练完成，小学习率需要与训练预算一起考虑。后续对照采用学习率0.0001，统一训练100轮，比较末轮结果。

高学习率组则出现了另一种情况：验证损失在第22轮最低，之后略有回升，训练损失却继续下降。这提示后段训练可能没有继续改善泛化。两组现象不能用同一种解释概括；本次为统一比较保留固定轮数，早停可以作为下一步检验。

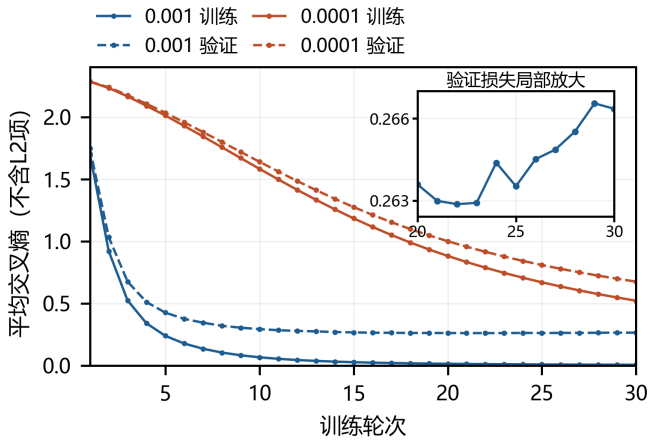


图 1 训练与验证损失均取每轮完整数据上的均值。右上角放大高学习率组第20至30轮的验证损失，坐标范围单独标明。

3 正则化和加权能否修正错误

如果差距主要来自约束不足，增强正则化应有机会改善验证表现。固定学习率0.0001、50神经元和100轮，将alpha从0.005提高到0.05后，训练拟合程度下降了，但验证准确率也从91.59%降至90.43%。原先想靠更强约束改善差距的办法没有奏效。

L2是在分类损失之外增加权重大小的惩罚。它可以抑制对训练样本的过度依赖，也可能压制有用的区分信息。因此，训练拟合下降本身不是改进，仍要看验证文本是否分得更好。另外，MLP的alpha越大惩罚越强，逻辑回归的C越大惩罚却越弱，不能把这两个参数按同一方向理解。

接着回到未加权的50宽MLP检查类别表现。类别2召回率为81.63%，于是把训练集中该类权重设为1.5倍并作均值归一；验证仍按原始分布等权评价。加权后类别2召回升至85.03%，类别1却从91.89%降至91.22%。整体修正6篇、新增1篇错误，验证准确率略升，交叉熵却从0.2940升至0.2960。因此，加权有局部收益，也有代价，需要结合具体错误判断。

原文片段（样本索引）	真类	普通→加权
3520：information about this drive. Switch settings, geometry..etc.	2	7→2
6878：I'm running a 286dx-25 with a 85mb hdd. I also have windows 3.1	1	1→2

表 1 第一条是按验证行序找到的首条修正，第二条是唯一新增错误。片段省去个人信息；标签仍沿用数据中的编号。

第二条文本同时提到硬件和系统软件，加权后类别2与1的概率十分接近，最后被判为2。这个例子说明了代价：加权调整的是模型对类别的重视程度，并没有补充区分这些文本的信息。它能修正部分错误，也可能把边界附近的正确样本推向另一类，所以没有继续提高权重。逻辑回归的类别7权重对照也有类似取舍，完整结果留在记录中。

从训练目标看，更大的权重会提高分错这一类的代价，使这些样本对参数更新的影响增加。分类边界由多个类别共同决定，变化也会影响其他类别。因而查看错例时同时保留“错变对”和“对变错”，才能判断改善是怎样发生的，而不是只挑修正成功的文本。

4 增加容量有多大帮助

随后回到未加权的MLP，检查模型容量。25个神经元增至50个时只少错1篇，50个增至100个时少错7篇；后一次的参数量也约翻倍。增加容量有帮助，但收益并不均匀，不能只因为训练拟合更高就继续加大网络。

为检查这点小幅优势是否只来自一次训练，用三个训练种子复验了50与100宽。100宽都高约0.4至0.5个百分点，因而后续表示实验固定为100神经元、alpha=0.005，其他训练设置不变。这几次仍用同一验证集，只说明优势在所试的训练随机状态下重复出现，不能当成三折交叉验证。

5 表示更复杂，效果未必更好

5.1 短语实验暴露了特征预算的取舍

单个词不能直接表达词间关系，因此尝试加入双词短语，验证准确率却从92.06%降至90.50%。检查词表后发现，5000个名额变成3137个单词和1863个短语：不是保留原有单词再加短语，而是两者共同占用名额。

总特征数和网络参数量不变，但短语可能替换了更有用的单词。TF-IDF数值也随之变化，不能仅凭这组结果断定原因就是名额竞争。若进一步检验，可保留原有单词，再额外增加短语；本次未做这项对照。

这次失败让我把问题从“还能加什么特征”转为“原有单词是否被词表上限截断”，因而继续做扩大单词词表的对照。

5.2 词频缩放让我重新区分两种指标

又尝试对数词频，让重复出现的词影响增长得更慢。同一词表和IDF下，它比普通词频多错4篇，平均交叉熵却从0.2821降至0.2701。

单条交叉熵为-log p(真实类别)，准确率则只看最大概率对应的类别。少量边界样本换类会降低准确率，其他文本的真实类别概率提高却可能降低平均损失。因此，低损失不一定意味着少错分，也不能仅凭它断言概率校准更好。

这个改动并非完全无效，但未改善本次优先考虑的分类准确率，后续仍用普通词频。

5.3 换分类器也没有直接解决问题

在同样的5000词TF-IDF上补做线性SVM。调大C后仍未超过LR或100宽MLP，换分类器没有直接突破，因而进一步检查共同的输入特征。

LR将线性得分经softmax转为10类概率，用L-BFGS优化交叉熵加L2惩罚，迭代上限1000。线性核SVM用软间隔目标平衡间隔大小与违例惩罚，多类采用两两分类。两者都利用高维稀疏词特征，但前者拟合概率，后者侧重间隔。SVM未启用概率输出，不比较交叉熵。

5.4 删除来源信息，会不会更可靠

最后固定10000词、LR C=100和原划分，检查模型是否依赖来源信息。只删除能可靠解析的邮件头中预先指定的来源字段及折行，保留Subject等主题字段、未知字段；再比较额外删除明确以独立行“-- ”标记的签名。规则不按验证成绩修改，各组重新在训练部分拟合TF-IDF。

文本处理	验证准确率	验证交叉熵
原文复训	93.01%	0.2709
去指定来源头	93.15%	0.2569
再去标记签名	92.94%	0.2623

表 2 三组训练准确率均为99.98%，实际均为10000特征。

去来源头净少错2篇，背后却是修正26篇、新错24篇；再去签名比只去头多错3篇。可见删得更多未必更好，整体小幅变化也会掩盖大量双向换错。签名可能有主题线索，启发式规则也可能误删；本次没有逐一验证。结果只说明去指定来源字段后仍能取得相近表现，不能证明没有来源依赖或跨来源泛化更好。

6 扩词表对照与最终选择

将单词词表上限从5000扩至10000，各模型保留自身其他设置：逻辑回归和SVM均为C=100，MLP沿用前述100宽、低学习率和100轮配置。三者都不加权，使用普通词频和相同的数据划分。

模型	5000词	10000词
LR C=100	91.45%	93.01%
MLP 隐藏100	92.06%	92.88%
SVM C=100	91.04%	91.79%

表 3 扩词表后的验证准确率。MLP统一比较第100轮，不分别选各组最好的一轮。

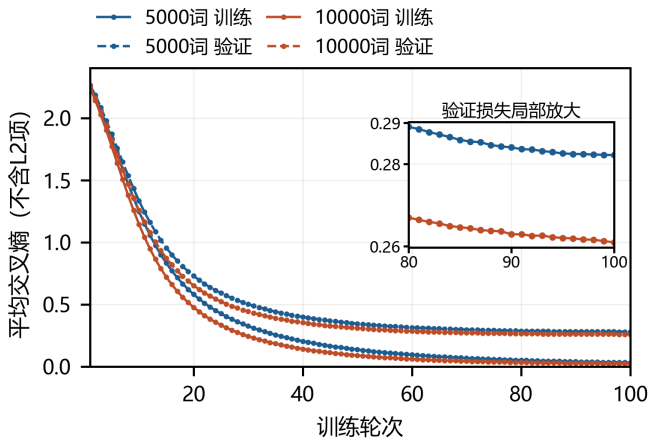


图 2 扩词表后MLP的验证损失较低。右上角放大第80至100轮，主图仍保留全部训练与验证逐轮点。

三个模型都得到改善，说明输入表示值得检查，而非只调整网络参数。这与短语实验失败并不矛盾：短语在固定名额内替换部分单词，扩词表则保留更多单词，两者对原有信息的处理不同。

扩词表也改变归一化后的输入，并增加MLP参数量、改变初始化，因而不能把改善全部归于新增单词。结果支持本次10000词配置，不能外推到更大词表。

原29组对照后选择了10000词、C=100的原文LR。它比MLP只少错2篇，不能认定优势稳定；但LR约10万参数，MLP约100万。同机纯拟合耗时约1.7秒和370.1秒，不含特征提取及逐轮评价。MLP交叉熵更低，而本次以分类结果为主，效果接近时选择成本较低的LR；耗时仅反映本次实现与预算。

补充清洗后，去来源头的准确率略高，但净收益仅2篇且有大量双向换错，尚不能确认稳定优势。本次保留已选原文模型，并不是认定它优于清洗模型。

回看这些尝试，“训练接近100%，所以加正则化”的判断过于简单。曲线区分训练不足与后段反弹，错例揭示加权代价，短语实验引出词表预算，清洗也有取舍。失败的改动同样缩小了检查范围。

多次依据同一验证集调参，可能让选择适应该划分。三个训练种子只检查训练随机性，不能替代新划分。后续应固定候选，用多个分层划分复验；本次未做，当前成绩不是独立测试结果。

选定后，用全部7368篇有标签文本重拟合词表、IDF和模型，按2457篇测试文本原行序生成单列、无表头和索引的prediction.csv。原验证集已参与重训，因此报告成绩仅属于先前留出阶段；测试无标签，不报告准确率。